

交通大数据

时间序列分析



概述

□ 时间序列

- 在一定时间内，**按时间顺序测量的某个变量**的取值序列
 - 某路段每小时车流量的变化
 - 某地区每天交通事故数的变化

□ 时间序列分析

- 使用**统计方法**对序列的**过去**进行分析
 - 对变量的时间变化特性建模
 - 对变量的未来取值进行预测
- 研究过去预测未来！



概述

□ 时间序列分类

- **一元时间序列** vs. 多元时间序列
- **离散时间序列** vs. 连续时间序列
- **平稳时间序列** (均值为常数、协方差为时间间隔的函数)
vs. 非平稳时间序列 (均值、方差随时间变化)

□ 时间序列的特征

- **趋势**, 在某一方向上持续运动 (早高峰路段车流量持续增加)
- **季节变化** (冬天高速公路事故率增加)
- **序列相关性** (serial correlation) 或**自相关性** (autocorrelation)
 - 变量**时间前后**存在相关性
- **随机噪声** (不确定性运动)
 - 除去趋势、季节变化和自相关性之后, 剩下的随机扰动



概述


□ 时间序列分析方法

- 描述性方法（看图说话）

德国业余天文学家施瓦尔发现太阳黑子的活动具有11年左右的周期

- 统计方法

- **时域**（时间上的相关性） vs. **频域**（分解为不同频率的周期波动,傅里叶变换）



时间序列模型

□ 时间序列三种模型

通常用 T_t 表示长期趋势项, S_t 表示季节变动趋势项, C_t 表示循环变动趋势项, R_t 表示随机干扰项。常见的确定性时间序列模型有以下几种类型:

(1) 加法模型

$$y_t = T_t + S_t + C_t + R_t$$

(2) 乘法模型

$$y_t = T_t \cdot S_t \cdot C_t \cdot R_t$$

(3) 混合模型

$$y_t = T_t \cdot S_t + R_t$$

$$y_t = S_t + T_t \cdot C_t \cdot R_t$$

其中 y_t 是观测目标的观测记录, $E(R_t) = 0$, $E(R_t^2) = \sigma^2$ 。https://blog.csdn.net/qq_29831163



时间序列模型

□ 时间序列之移动平均法

- 根据时间序列资料逐渐推移，依次计算包含一定项数的时序平均数，以反映长期趋势。
- 当时间序列由于受周期变动和不规则变动的影响，起伏较大，不易显示出发展趋势时，可用移动平均法，消除这些因素的影响，分析、预测长期趋势
- 简单移动平均法
- 加权移动平均法



时间序列模型

□ 时间序列之移动平均法：简单移动平均法

设观测序列为 $y_1, \dots, y_T$ ，取移动平均的项数 $N < T$ 。一次简单移动平均值计算公式为：

$$\begin{aligned} M_t^{(1)} &= \frac{1}{N} (y_t + y_{t-1} + \dots + y_{t-N+1}) \\ &= \frac{1}{N} (y_{t-1} + \dots + y_{t-N}) + \frac{1}{N} (y_t - y_{t-N}) = M_{t-1}^{(1)} + \frac{1}{N} (y_t - y_{t-N}) \end{aligned} \quad (1)$$

当预测目标的基本趋势是在某一水平上下波动时，可用一次简单移动平均方法建立预测模型：

$$\hat{y}_{t+1} = M_t^{(1)} = \frac{1}{N} (\hat{y}_t + \dots + \hat{y}_{t-N+1}), \quad t = N, N+1, \dots, \quad (2)$$

其预测标准误差为：

$$S = \sqrt{\frac{\sum_{t=N+1}^T (\hat{y}_t - y_t)^2}{T - N}}, \quad (3)$$

时间序列模型

时间序列之移动平均法：简单移动平均法

- 某企业 1-11 月份的销售收入时间序列如表 1 示。试用一次简单滑动平均法预测第 12 月份的销售收入。

表 1 企业销售收入

月份 t	1	2	3	4	5	6
销售收入 y_t	533.8	574.6	606.9	649.8	705.1	772.0
月份 t	7	8	9	10	11	
销售收入 y_t	816.4	892.7	963.9	1015.1	1102.7	

解： 分别取 $N = 4, N = 5$ 的预测公式

$$\hat{y}_{t+1}^{(1)} = \frac{y_t + y_{t-1} + y_{t-2} + y_{t-3}}{4}, \quad t = 4, 5, \dots, 11$$

$$\hat{y}_{t+1}^{(2)} = \frac{y_t + y_{t-1} + y_{t-2} + y_{t-3} + y_{t-4}}{5}, \quad t = 5, \dots, 11$$

当 $N = 4$ 时，预测值 $\hat{y}_{12}^{(1)} = 993.6$ ，预测的标准误差为

$$S_1 = \sqrt{\frac{\sum_{t=5}^{11} (\hat{y}_t^{(1)} - y_t)^2}{11 - 4}} = 150.5$$

当 $N = 5$ 时，预测值 $\hat{y}_{12}^{(2)} = 182.4$ ，预测的标准误差为

$$S_2 = \sqrt{\frac{\sum_{t=6}^{11} (\hat{y}_t^{(2)} - y_t)^2}{11 - 5}} = 958.2$$



时间序列模型

□ 时间序列之移动平均法：加权移动平均法

- 在简单移动平均中，每期数据在求平均时的作用是等同的。
- 但是数据所包含的信息量不一样，**近期数据包含着更多关于未来情况的信息。**
- 把各期数据等同看待是不尽合理的，应**考虑各期数据的重要性，对近期数据给予较大的权重。**

设时间序列为 $y_1, y_2, \dots, y_t, \dots$ ；加权移动平均公式为

$$M_{tw} = \frac{w_1 y_t + w_2 y_{t-1} + \dots + w_N y_{t-N+1}}{w_1 + w_2 + \dots + w_N}, \quad t \geq N \quad (4)$$

式中 M_{tw} 为 t 期加权移动平均数； w_i 为 y_{t-i+1} 的权数，它体现了相应的 y_t 在加权平均数中的重要性。

利用加权移动平均数来做预测，其预测公式为

$$\hat{y}_{t+1} = M_{tw} \quad (5)$$

即以第 t 期加权移动平均数作为第 $t+1$ 期的预测值。



时间序列模型

□ 时间序列之移动平均法：加权移动平均法

- 我国1979-1988年原煤产量如表2所示。试用加权移动平均法预测1989年的产量。

表2 我国原煤产量统计数据及加权移动平均预测值表

年份	1979	1980	1981	1982	1983	1984	1985	1986	1987	1988
原煤产量 y_t	6.35	6.20	6.22	6.66	7.15	7.89	8.72	8.94	9.28	9.8
三年加权移动平均预测值				6.235	6.4367	6.8317	7.4383	8.1817	8.6917	9.0733
相对误差 (%)				6.38	9.98	13.41	14.7	8.48	6.34	7.41



时间序列模型

□ 时间序列之移动平均法：加权移动平均法

解 取 $w_1 = 3, w_2 = 2, w_3 = 1$ ，按预测公式

$$\hat{y}_{t+1} = \frac{3y_t + 2y_{t-1} + y_{t-2}}{3 + 2 + 1}$$

计算三年加权移动平均预测值，其结果列于表 2 中。1989 年我国原煤产量的预测值为（亿吨）

$$\hat{y}_{1989} = \frac{3 \times 9.8 + 2 \times 9.28 + 8.94}{6} = 9.48$$

这个预测值偏低，可以修正。其方法是：先计算各年预测值与实际值的相对误差，例如 1982 年为

$$\frac{6.66 - 6.235}{6.66} = 6.38\%$$

将相对误差列于表 2 中，再计算总的平均相对误差。

$$\left(1 - \frac{\sum \hat{y}_t}{\sum y_t}\right) \times 100\% = \left(1 - \frac{52.89}{58.44}\right) \times 100\% = 9.5\%$$

由于总预测值的平均值比实际值低 9.5%，所以可将 1989 年的预测值修正为

$$\frac{9.48}{1 - 9.5\%} = 10.4788$$



基本原理

□ 平稳时间序列模型

- 自回归 (autoregressive, AR) 模型
- 移动平均 (moving average, MA) 模型
- 自回归移动平均 (autoregressive moving average, ARMA) 模型
- 差分自回归移动平均 (autoregressive integrated moving average, ARIMA) 模型



基本原理

□ 时间序列的平稳性 (stationarity)

- 严格平稳性 (strict stationarity)

- 任意给定长度的两段子序列都满足相同的联合分布

- **弱平稳性** (weak stationarity)

- **均值平稳性** (stationary in mean, first order stationary)

对于所有的时刻 t , 有 $E[r_t] = \mu$, 其中 μ 是一个常数

- **方差平稳性** (stationary in variance, second order stationary)


对于所有的时刻 t 和任意的间隔 k , r_t 和 r_{t-k} 的协方差 $\sigma(r_t, r_{t-k}) = \gamma_k$, 其中 γ_k 与时间 t 无关, 它仅仅依赖于间隔 k 。特别的, 当 $k = 0$ 时, 这个特性意味着 $\sigma(r_t, r_t)$ —— r_t 的方差 —— 不随时间变化, 等于一个与时间 t 无关的常数 γ_0



基本原理

□ 时间序列的平稳性 (stationarity)

- 根据弱平稳性，时间序列应该在一个常数值附近随机波动（均值平稳性），波动的范围有界（方差平稳性），无明显趋势、周期特征



基本原理

□ 时间序列的自相关性

- 考察当前 t 时刻与距离当前任意间隔 k 时刻，变量间的线性相关关系

r_t 和 r_{t-k} 的相关系数称为 r_t 的间隔为 k 的自相关系数

$$\rho_k = \frac{\text{Cov}(r_t, r_{t-k})}{\sigma_{r_t} \sigma_{r_{t-k}}} = \frac{\text{Cov}(r_t, r_{t-k})}{\sigma_{r_t} \sigma_{r_t}} = \frac{\gamma_k}{\gamma_0}$$

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$

$$\rho_k = \rho_{-k}$$

$$-1 \leq \rho_k \leq 1$$



基本原理

□ 时间序列模型之 AR 篇

- $x_t = \varphi_0 + \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \cdots + \varphi_p x_{t-p} + \varepsilon_t$
 - $\varphi_p \neq 0$
 - $E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t$
 - $E(x_s \varepsilon_t) = 0, \forall s < t$
- 线性回归模型，但自变量是序列自身（历史观测值）→ “自” 回归



基本原理

□ 时间序列模型之 AR 篇

▪ 一阶自回归

$$x_t = \phi_1 x_{t-1} + e_t$$

$$x_t - \phi_1 x_{t-1} = e_t$$

$$(1 - \phi_1 B)x_t = e_t \rightarrow Bx_t = x_{t-1}, B \text{ 称为延迟算子}$$

▪ 二阶自回归

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + e_t$$

$$x_t - \phi_1 x_{t-1} - \phi_2 x_{t-2} = e_t$$

$$(1 - \phi_1 B - \phi_2 B^2)x_t = e_t \rightarrow Bx_t = x_{t-1}, B^2 x_t = x_{t-2}, \dots$$



基本原理

□ 时间序列模型之 MA 篇

- $x_t = u + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}$
 - $\theta_q \neq 0$
 - $E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t$
- $u = 0 \rightarrow$ 中心化 MA(q) 模型
 - $x_t = \Theta(B)\varepsilon_t, \Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$
- MA 模型**一定满足**平稳性要求



基本原理

□ 时间序列模型之 MA 篇

- 均值

- $Ex_t = E(\mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_2\varepsilon_{t-2} - \cdots - \theta_q\varepsilon_{t-q}) = \mu$

- 方差

- $$\begin{aligned} Var(x_t) &= Var(\mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_2\varepsilon_{t-2} - \cdots - \theta_q\varepsilon_{t-q}) \\ &= (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma_\varepsilon^2 \end{aligned}$$



基本原理

□ 时间序列模型之 ARMA 篇

- p 阶自回归 + q 阶移动平均 $\rightarrow$ ARMA(p, q)
- $x_t = \varphi_0 + \varphi_1 x_{t-1} + \cdots + \varphi_p x_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}$
 - $\varphi_p \neq 0, \theta_q \neq 0$
 - $E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t$
 - $E(x_s \varepsilon_t) = 0, \forall s < t$



基本原理

□ 时间序列模型之 ARMA 篇

- p 和 q 的选取 (防止过拟合)
 - 自相关图
 - 使用信息量准则 (越小越好)
 - 赤池信息量准则 (Akaike information criterion, AIC)
$$\text{AIC} = -2 \ln L + 2k$$
 - 贝叶斯信息量准则 (Bayesian information criterion, BIC)
$$\text{BIC} = -2 \ln L + k \ln n$$
 - 拟合度好坏+参数个数惩罚: 有效性+集约型

▪ 参数估计



- 矩估计 vs. 极大似然估计 vs. 最小二乘
- [ARMA模型的参数估计 - 百度文库 \(baidu.com\)](#)



基本原理

□ 时间序列的自相关性


- 自相关函数
 - 时间序列重要特性
 - 自相关性随 k 变化
 - 通常具有短期相关性，即自相关系数随间隔数的增加很快衰减



基本原理

□ 时间序列的自相关性

- 画出相关图
 - 可以检测时间序列在任何间隔 k 有无统计上显著的自相关性
 - 可以帮助判断模型是否合适
- 若模型很好地捕捉了自相关性，则观测时间序列与模型拟合时间序列间的残差应近似随机噪声



基本原理

□ 时间序列分析的一般步骤

- 通过相关图（以及假设检验）了解观测时间序列的自相关性
- 选取时间序列模型，如 ARMA 模型
- 优化模型参数，检验残差序列是否在统计上显著自相关
- 进行模型预测，考察泛化能力
- 重复上述步骤直至满足建模要求



基本原理

□ 时间序列模型的建模步骤

