

交通大数据理论与方法

凸规划与梯度下降算法

- 刘志远教授
- Email: zhiyuanl@seu.edu.cn



非线性规划


□ 学习目标

- 了解非线性规划（Nonlinear Programming, NLP）与凸规划（Convex Programming）的概念和分类；
- 学习KKT（Karush-Kuhn-Tucker）条件；
- 知道如何用KKT条件找到局部最优解；
- 了解求解凸规划问题的最速下降方向法；
- 掌握求解凸规划问题的Frank-Wolfe算法。



数学规划

- ☐ 线性规划
- ☐ 非线性规划
- ☐ 动态规划
- ☐ 图论
- ☐ 随机规划
- ☐



NLP的定义

□ 问题描述

确定一组决策变量的值,使目标函数达到最优,同时满足约束条件。

$\min$ (or $\max$) $f(x_1, \dots, x_n)$ ← 目标函数

subject to

$$g_1(x_1, \dots, x_n) \leq 0$$

$$g_2(x_1, \dots, x_n) \leq 0$$

$$\vdots$$

$$g_{m_1}(x_1, \dots, x_n) \leq 0$$

$$h_1(x_1, \dots, x_n) = 0$$

$$h_2(x_1, \dots, x_n) = 0$$

$$\vdots$$

$$h_{m_2}(x_1, \dots, x_n) = 0$$

← 不等式约束

← 等式约束



NLP的定义

➤ 向量表示:

- 决策变量: $x = (x_1, \dots, x_n)^T$
- 不等式约束: $g = (g_1, \dots, g_{m_1})^T$
- 等式约束: $h = (h_1, \dots, h_{m_2})^T$

➤ 假设

$f(x)$, $g(x)$ 和 $h(x)$ 都是连续可微函数

➤ 非线性规划的向量表示

$$\min_x f(x)$$

subject to

$$g(x) \leq 0$$

$$h(x) = 0$$

$$\min_{x \in \Omega} f(x)$$

where

$$\Omega = \{x \mid g(x) \leq 0, h(x) = 0\}$$

- 注意向量和集合的符号表达。




基础知识点

□NLP的求解难点

1. 局部最优 $\neq$ 全局最优
2. 与 LP相比, NLP的最优值可能不是在极值点 (顶点) 处出现
3. 即使 $f(x)$ 是有界的, 也可能不存在最优解

例如


$$f(x) = 1 - \frac{1}{x}, \Omega = \{x : x \geq 0.5\}, \Rightarrow \max_{x \in \Omega} f(x) = ?$$



4. 可行域可能不是相互连接的

例如


$$\Omega = \{x : g_1(x) \geq g_2(x)\}$$




基础知识点

□ 极大值解和极小值解

- $x^*=1$ 是函数 $f_1(x)$ 的全局极小值解
- $x^*=1$ 是函数 $f_2(x)$ 的全局极大值解




(a) 函数 $f_1(x) = (x-1)^2 + 0.5$



(b) 函数 $f_2(x) = 0.5 - (x-1)^2$

基础知识点

- 函数 $f_3(x)$ 的全局极小值解和极大值解分别是什么？
- 函数 $f_3(x)$ 在可行域 $-5 \leq x \leq 2$ 内的全局极小值解和极大值解分别是什么？



(c) 函数 $f_3(x) = (x^2)$



基础知识点

□ 最小化问题的全局极小值解和局部极小值解

$$\min_{x \in \Omega} f(x)$$

■ 全局极小值解 x^*

(i) (可行性) x^* 是极小化问题的一个可行解, 即 $x^* \in \Omega$

(ii) (最优性) 对于任意的 $x \in \Omega$ 都满足 $f(x) \geq f(x^*)$

■ 局部极小值解 $\bar{x}$

(i) (可行性) $\bar{x}$ 是极小化问题的一个可行解, 即 $\bar{x} \in \Omega$

(ii) (最优性) 对于 $\bar{x}$ 邻域内的任意 x 都满足 $f(x) \geq f(\bar{x})$



多元函数


□例

$$(1) f_1(x) = (x_1 - 2)^2 + (x_2 - 2)^2$$

$$\text{向量: } x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2$$

$$(2) f_2(x) = 2x_1 + 3x_2 + 0.5x_3 - x_4$$

$$\text{向量: } x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} \in \mathbb{R}^4$$



多元函数--梯度

□ 一个 n 元函数 $f(x)$ 在最优解 $x=x^*$ 处的梯度可表示为:

$$\nabla f(x^*) = \begin{pmatrix} \partial f(x^*) / \partial x_1 \\ \partial f(x^*) / \partial x_2 \\ \vdots \\ \partial f(x^*) / \partial x_n \end{pmatrix}$$

$$f: R^n \rightarrow R^1$$

what if $R^n \rightarrow R^n$?

*Jacobian*矩阵

■ 例

$$(1) f_1(x) = (x_1 - 2)^2 + (x_2 - 2)^2$$



$$\nabla f_1(x^*) = \begin{pmatrix} 2(x_1^* - 2) \\ 2(x_2^* - 2) \end{pmatrix}$$

$$(2) f_2(x) = 2x_1 + 3x_2 + 0.5x_3 - x_4$$



$$\nabla f_2(x^*) = \begin{pmatrix} 2 \\ 3 \\ 0.5 \\ -1 \end{pmatrix}$$



多元函数--梯度

▣梯度的几何解释

给定一个函数 $f(x)=x_1+x_2$,


在点 $x=(2,1)$ 处, 梯度为:

$$\nabla f(2,1) = (1,1)^T$$

✓ 观察发现:


1. 当沿着点 x 的**梯度方向**移动时, 函数值将增加;
2. 当沿着点 x 的**负梯度方向**移动时, 函数值将减小。

对于使目标函数值最小的问题, 负梯度方向为其提供了一个重要的线索。如何证明?




多元函数--梯度

▣梯度的几何解释



$$z = (x_1 - 2)^2 + (x_2 - 2)^2$$

$$\nabla z(1.4, 1.4) = (-1.2, -1.2)$$



Representation in contours

多元函数—海塞矩阵

□ n 元函数 $f(x)$ 在最优解 $x=x^*$ 处的海塞矩阵可表示为:

$$\nabla^2 f(x^*) = \begin{bmatrix} \partial^2 f(x^*)/\partial^2 x_1 & \partial^2 f(x^*)/\partial x_1 \partial x_2 & \cdots & \partial^2 f(x^*)/\partial x_1 \partial x_n \\ \partial^2 f(x^*)/\partial x_2 \partial x_1 & \partial^2 f(x^*)/\partial^2 x_2 & \cdots & \partial^2 f(x^*)/\partial x_2 \partial x_n \\ \vdots & \vdots & \vdots & \vdots \\ \partial^2 f(x^*)/\partial x_n \partial x_1 & \partial^2 f(x^*)/\partial x_n \partial x_2 & \cdots & \partial^2 f(x^*)/\partial^2 x_2 \end{bmatrix}_{n \times n}$$

■ 例

$$(1) f_1(x) = (x_1 - 2)^2 + (x_2 - 2)^2$$


$$\nabla^2 f(x^*) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$(2) f_2(x) = 2x_1 + 3x_2 + 0.5x_3 - x_4$$


$$\nabla^2 f_2(x^*) = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$



矩阵正定的定义

A 是一个 $n \times n$ 的矩阵

■ 正定矩阵

对于任意非零向量 x , 矩阵 A 都满足 $x^T A x > 0$

■ 半正定矩阵

对于任意非零向量 x , 矩阵 A 都满足 $x^T A x \geq 0$

■ 正定的充要条件

如果矩阵 A 的 $k(k=1,2,\dots,n)$ 阶顺序主子式都大于0, 那么矩阵 A 是正定的

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \quad |a_{11}| > 0 \quad \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} > 0 \quad \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} > 0$$



基础知识： NLP的可行方向

$$\min_{x \in \Omega} f(x) \quad \text{where } \Omega \subseteq R^n$$

■ 点 x 处的可行方向 d

当一个方向 d (即一个 n 维向量) 是可行域 Ω 内点 x 处的可行方向时, 那么存在参数 $\bar{\alpha}$ 使方向 d 满足:


$$x + \alpha d \in \Omega \text{ for all } 0 \leq \alpha \leq \bar{\alpha}$$

例: $\Omega = \{(x_1, x_2) | x_1 + x_2 \leq 2, x_1 \geq 0, x_2 \geq 0\}$

✓ 对于内点 $(1, 0.5)$, 任意一个方向都是可行方向(Why?)

✓ 对于顶点 $(2, 0)$, 可行方向: $d = (1, 0.5) - (2, 0) = (-1, 0.5)$

不可行方向: $d = (3, 1.5) - (2, 0) = (1, 1.5)$




基础知识： NLP的可行方向

- 起作用约束（binding constraints）

$$g_i(\mathbf{X}) \leq 0 \quad i = 1, 2, \dots, m$$

假设 $\mathbf{D}$ 是点 $\mathbf{X}^*$ 处的可行方向； j 是点 $\mathbf{X}^*$ 处起作用的约束，即 $g_j(\mathbf{X}^*) = 0$ 。假设 $\mathbf{J}$ 是点 $\mathbf{X}^*$ 处所有起作用约束的集合，则 $\nabla g_j(\mathbf{X}^*)^T \mathbf{D} < 0, j \in \mathbf{J}$



基础知识： NLP的可行方向

$$X = X^* + \lambda D$$

λ : 步长

证明：用泰勒展开

$$f(X) = f(X^*) + \nabla f(X^*)^T (X - X^*) + o(X - X^*)$$

$$g_j(X^* + \lambda D) = g_j(X^*) + \lambda \nabla g_j(X^*)^T D + o(\lambda)$$

因为 $g_j(X^*) = 0$

而且，步长 $\lambda > 0$, $g_j(X^* + \lambda D) \leq 0, j \in J$

所以 $\nabla g_j(X^*)^T D < 0, j \in J$

对于不起作用约束：即 $g_i(X^*) < 0, i \notin J$

对于任意方向D，总存在 $\lambda > 0$ ，满足 $g_i(X^* + \lambda D) \leq 0, i \notin J$



基础知识： NLP的下降方向

▣NLP的下降方向

- 如果向量 D 是点 $X^{(0)}$ 处的下降方向, 那么存在实数 $\lambda > 0$, 满足

$$f(X^{(0)} + \lambda D) < f(X^{(0)})$$

- 对于任意下降方向, 我们进一步可得到 $\nabla f(X^{(0)})^T D < 0$

- 证明: 由 $f(X)$ 在点 $X^{(0)}$ 处的泰勒展开, 可得:

$$f(X^{(0)} + \lambda D) = f(X^{(0)}) + \nabla f(X^{(0)})^T \lambda D + o(\lambda)$$

$$f(X^{(0)} + \lambda D) - f(X^{(0)}) < 0 \Rightarrow \nabla f(X^{(0)})^T \lambda D < 0$$

$$\nabla f(X^{(0)})^T D < 0$$

重要的结论:


负梯度方向是最速下降方向




基础知识： NLP的下降方向

▣NLP的下降方向

例: $\Omega = \{(x_1, x_2) | x_1 + x_2 \leq 2, x_1 \geq 0, x_2 \geq 0\}$, $f(x) = (x_1 - 1)^2 + (x_2 - 2)^2$



在可行域内部点 $(1, 0.5)$ 处
可行下降方向为 d_1, d_2, d_3



在可行域边界点 $(2, 0)$ 处
可行下降方向为 d_5

基础知识： NLP的下降方向

□NLP的可行下降方向

从字面上讲，**可行下降方向**即同时满足可行性和使函数值减小的方向

- 如果 $X^{(0)}$ 不是一个局部极小值点，那么求解算法下次迭代的搜索方向应该是该点的可行下降方向；
- 如果 $X^{(0)}$ 是一个极小值点，那么该点没有可行下降方向；
- 反过来讲，如果一个点有可行下降方向，那么该点一定不是局部极小值点



基础知识： NLP的下降方向

▣NLP的可行下降方向

从数学表达来看，如果点 $X^{(0)}$ 不是局部极小值点，那么一定存在一个方向 D 满足如下不等式条件：

$$\begin{cases} \nabla f(X^{(0)})^T D < 0 \\ \nabla g_j(X^{(0)})^T D < 0, j \in J \end{cases}$$

从坐标空间来看，

- 可行下降方向 D 和目标函数的负梯度方向的夹角是锐角；
- 可行下降方向 D 和起作用约束的负梯度方向的夹角是锐角；



凸优化 (Convex Optimization)

凸优化

- 凸优化（也称：凸规划，Convex Programming）
- 凸优化是非线性规划的一个特殊子集，比一般的NLP模型更容易求解。需满足两个条件：
 - 可行域为凸集
 - 目标函数为凸函数

$$\min_{x \in \Omega} f(x)$$

where

$$\Omega = \{x \mid g(x) \leq 0, h(x) = 0\}$$



凸集 (Convex Set)

设 Ω 表示 n 维实数域 $\mathbb{R}^n$ 内的一个集合


• 定义

集合内任意两点 $x_1, x_2 \in \Omega$ ，任意实数 $\alpha (0 \leq \alpha \leq 1)$ 使 $\alpha x_1 + (1 - \alpha)x_2 \in \Omega$ ，则称集合 Ω 为凸集。

即，集合内任意两点的连线间的点都在集合内。

例1:


$$\Omega_1 = \{(x_1, x_2) \mid x_1 + x_2 \leq 2; x_1 - x_2 \leq 1; x_1 \geq 0; x_2 \geq 0\}$$



凸集

- 例2:

$$\Omega_2 = \{(x_1, x_2) \mid (x_1 - 1)^2 + (x_2 - 1)^2 \leq 1\}$$




- 例3:

$$\Omega_3 = \{(x_1, x_2) \mid x_1 + x_2 \leq 3; g(x) \leq 0; x_1 \geq 0; x_2 \geq 0\}$$

其中

$$g(x) = \begin{cases} x_1 - x_2, & 0 \leq x_1 \leq 1 \\ 3 - x_1 - 2x_2, & x_1 \geq 1 \end{cases}$$




凸函数(Convex Function): 定义

函数 $f(x)$ 在凸集合 Ω 内的凸性为:

$$f(x_1 + \alpha(x_2 - x_1)) \leq f(x_1) + \alpha[f(x_2) - f(x_1)], \forall x_1, x_2 \in \Omega, \forall \alpha \in [0, 1]$$

$$f: R^n \rightarrow R$$

$$f(x_1) + \alpha[f(x_2) - f(x_1)]$$



- 其严格凸性为:

$$f(x_1 + \alpha(x_2 - x_1)) < f(x_1) + \alpha[f(x_2) - f(x_1)]$$

$$\forall x_1, x_2 \in \Omega, \forall \alpha \in [0, 1]$$

$$x_1 + \alpha(x_2 - x_1)$$



凸函数：一阶等价条件

如果 $f: R^n \rightarrow R$

在凸集合 Ω 内的任一点可微


■充分/必要条件

(i) f 在凸集合 Ω 内是凸函数的一阶等价条件是：

$$f(z) \geq f(x) + \nabla f(x)^T (z - x), \forall x, z \in \Omega$$

(ii) f 在凸集合 Ω 内是严格凸函数的一阶等价条件是：

$$f(z) > f(x) + \nabla f(x)^T (z - x), \forall x \neq z, x, z \in \Omega$$



凸函数：二阶等价条件

□ 检验函数凸性的条件

假设对于凸集合 Ω 内的任意可行点处的海塞矩阵 $\nabla^2 f(x)$ 都存在

■ f 在凸集合 Ω 内是凸函数的二阶等价条件是

(i) 当且仅当海塞矩阵 $\nabla^2 f(x)$ 是半正定矩阵时，函数

$f(x)$ 是凸函数；

(ii) 当且仅当海塞矩阵 $\nabla^2 f(x)$ 是正定矩阵时，函数 $f(x)$ 是严

格凸函数；



凸函数

• 例

- 函数 $f_1(x) = (x_1 - 2)^2 + (x_2 - 2)^2$

它是一个凸函数

- 函数 $f_2(x) = 2x_1 + 3x_2 + 0.5x_3 - x_4$

它是一个凸函数但不是严格凸函数

- 注意：

所有的线性函数都是凸函数。是不是凹函数？



凸函数

- 例 1:

证明 $f(x) := \sum_{j=1}^n c_j x_j$ 在它的自然域内是凸函数

- 例 2:

假设 $c_j > 0, j = 1, 2 \cdots n$.

证明 $f(x) := \sum_{j=1}^n c_j x_j^2$ 是一个凸函数(提示: $2ab \leq a^2 + b^2$)

- 例 3:

试举例写出 $c_j (j = 1, 2 \cdots n)$ 的值,

满足 $f(x) := \sum_{j=1}^n c_j x_j^2$ 不是凸函数



凸函数

□关于凸优化问题的阐述:

- 如果局部极小值点存在, 那么该局部极小值点是全局极小值点.
- 所有（全局）极小值点的集合是凸集
- 对于每个严格凸函数, 如果该函数有一个极小值, 那么该极小值是唯一的。

□例:

- 最小二乘法
- 线性规划
- 受线性约束的凸二次最优化
- 锥优化
- 有约束的熵最大化问题



凸优化问题的极小值和极大值

局部极小值点

如果 x^* 是凸集 Ω 内的一点, 对于点 x^* 处的任意可行方向 d 满足 $\nabla f(x^*)^T d \geq 0$, 那么 x^* 是凸规划问题 $\min_{x \in \Omega} f(x)$ 的一个全局极小值点

证明:

假设 x^* 不是全局极小值点, 那么在集合内 Ω 存在点 y 满足 $f(y) < f(x^*)$.

因为 Ω 是凸集, 对于任意 $0 \leq \alpha \leq 1$, $x^* + \alpha(y - x^*)$ 仍在凸集 Ω 内. 换句话说, $y - x^*$ 是点 x^* 处的可行方向。

因为 $f(x)$ 是凸函数, 那么可得

$$f(y) \geq f(x^*) + \nabla f(x^*)^T (y - x^*) \geq f(x^*)$$

这与假设矛盾



KKT条件

KKT条件

□ 怎样证明 x^* 是下列非线性规划的局部极小值点：

$$\begin{array}{ll} \min f(x) & \text{构造对偶乘子:} \\ \text{s.t.} & \text{(拉格朗日乘子)} \\ & g_i(x) \leq 0, \quad i = 1, \dots, m_1 \quad u_i \\ & h_j(x) = 0, \quad j = 1, \dots, m_2 \quad \lambda_j \end{array}$$

或者，怎样有效地找到局部极小值？



KKT条件

□必要最优性条件

如果 x^* 是一个局部极小值点, 那么存在拉格朗日乘子 $\{u_1, u_2, \dots, u_{m_1}\}$ 和 $\{\lambda_1, \lambda_2, \dots, \lambda_{m_2}\}$ 满足下列KKT条件:

$$(1) \nabla f(x^*) + \sum_{i=1}^{m_1} u_i \nabla g_i(x^*) + \sum_{j=1}^{m_2} \lambda_j \nabla h_j(x^*) = 0 \quad \leftarrow \text{(KKT等式)}$$

$$(2) u_i \geq 0, i = 1, \dots, m_1 \quad \leftarrow \text{(非负约束)}$$

$$(3) u_i g_i(x^*) = 0, i = 1, \dots, m_1 \quad \leftarrow \text{(互补松弛条件)}$$

$$(4) g_i(x^*) \leq 0, i = 1, \dots, m_1, h_j(x^*) = 0, j = 1, \dots, m_2 \quad \leftarrow \text{(可行性)}$$



约束条件 (CQ) 或正则条件 (阅读)

- 当KKT条件成立时, $g_i(x)$ 和 $h_j(x)$ 必须满足一定的正则条件 (通常也称为 **constraint qualifications**).
- 最常用的CQs如下:
- **线性约束条件(LCQ):**
如果 $g_i(x)$ 和 $h_j(x)$ 是仿射函数, 则不需要其他的条件成立.
- **线性独立约束条件 (LICQ):**
 $\nabla g_i(x)$ 和 $\nabla h_j(x)$ 是线性独立的.
-

Reference:

- Chapter 5 of *Nonlinear Programming: Theory and Algorithms* by Bazaraa et al. (1993)
- E스타quio, R. G., Karas, E. W., & Ribeiro, A. A. (2010). Constraint qualifications for nonlinear programming.



KKT 条件

- 注意

- KKT条件是NLP获得局部极小值的必要条件
- KKT条件是凸规划问题获得局部极小值的充要条件
 - 对于凸规划问题，任意一个局部极小值点就是全局极小值点。
 - 因此，KKT条件是凸规划问题获得全局极小值的充要条件。



KKT 条件

□ 例1

检查 $\mathbf{x}^*=(0.5,1.5)$ 是不是如下最小化问题的唯一全局最优解：

$$\begin{aligned} \min f(\mathbf{x}) &= (x_1 - 2)^2 + (x_2 - 3)^2 \\ \text{subject to} \end{aligned}$$

$$x_1 + x_2 \leq 2 \quad \leftarrow u_1$$

$$x_1 \geq 0 \quad \leftarrow u_2$$

$$x_2 \geq 0 \quad \leftarrow u_3$$

(1) 检验可行性条件

$$x_1^* + x_2^* = 2$$

$$x_1^* = 0.5 > 0$$

$$x_2^* = 1.5 > 0$$



KKT 条件

(2) 检验互补松弛条件

$$u_2 \times (-x_1^*) = 0, \quad u_3 \times (-x_2^*) = 0, \quad u_1^* \times (x_1^* + x_2^* - 2) = 0$$

可以知道 $u_2=0, u_3=0$ ，而 u_1 是一个未知的非负乘子

(3) 解KKT等式

$$\begin{pmatrix} 2(x_1^* - 2) \\ 2(x_2^* - 3) \end{pmatrix} + u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_3 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = 0 \quad \Rightarrow \quad u_1 = 3$$

(4) 检验非负条件

$$u_1 = 3 > 0, u_2 = 0, u_3 = 0$$

海塞矩阵 $\nabla^2 f(x) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 为正定，所以原问题为凸优化问题。

因此， $x^*=(0.5,1.5)$ 是原问题的唯一全局最优解。



KKT条件

例2：用KKT条件解如下非线性规划问题

$$\begin{cases} \min f(x) = (x-3)^2 \\ 0 \leq x \leq 5 \end{cases}$$

解：先将该非线性规划问题写成以下形式：

$$\begin{cases} \min f(x) = (x-3)^2 \\ g_1(x) = -x \leq 0 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

算出其目标函数和约束函数的梯度：

$$\nabla f(x) = 2(x-3),$$

$$\nabla g_1(x) = -1, \nabla g_2(x) = 1$$



KKT条件

□ 给出两个不等式约束的乘子

$$\begin{cases} \min f(x) = (x-3)^2 \\ g_1(x) = -x \leq 0 \\ g_2(x) = x-5 \leq 0 \end{cases} \quad \begin{array}{l} \text{两个约束的乘子:} \\ \gamma_1 \\ \gamma_2 \end{array}$$

□ 该问题的可行域为凸集,其目标方程为凸函数(求海塞矩阵可知), 因此该问题是一个凸优化问题。



KKT条件

根据KKT条件，某个局部最优解 $x^*, \gamma_1^*, \gamma_2^*$ 应该满足如下条件

$$\begin{aligned} 2(x^* - 3) - \gamma_1^* + \gamma_2^* &= 0 & \gamma_1^*, \gamma_2^* &\geq 0 \\ \gamma_1^* x^* &= 0 & -x^* &\leq 0 \\ \gamma_2^* (x^* - 5) &= 0 & x^* - 5 &\leq 0 \end{aligned}$$

为解上述方程组，分以下几种情形讨论：

- (1) 令 $\gamma_1^* \neq 0, \gamma_2^* \neq 0$, 无解;
- (2) 令 $\gamma_1^* \neq 0, \gamma_2^* = 0$, 解之, 得 $x^* = 0, \gamma_1^* = -6$, 不满足KKT条件;
- (3) 令 $\gamma_1^* = 0, \gamma_2^* \neq 0$, 解之, 得 $x^* = 5, \gamma_2^* = -4$, 不满足KKT条件;
- (4) 令 $\gamma_1^* = \gamma_2^* = 0$, 解之, 得 $x^* = 3$, 满足KKT条件, 得到局部最小值点。由于该问题为凸规划, 所以此为全局极小值点。



小结：KKT条件

- 目标函数和约束条件必须是连续可微的；
- 可行域需满足CQ，KKT条件才成立。
- 如果一个问题有多个局部最优解，那么就会有許多解都满足KKT条件。
- KKT包括许多等式和不等式，因此当问题规模变大之后，KKT条件很难直接求解。所以对于大规模问题，需要利用有效的算法来求解（下一节课）。



凸规划问题的求解算法

算法 (Algorithm) $x^0 \rightarrow x^n \rightarrow x^{n+1} \rightarrow x^*$


- 你对算法的理解是什么？
- 求解数学模型的算法过程包括什么？
 - 输入 (Input)
 - 初始化 (Initialization)
 - 下降方向 (Descent Direction)
 - 一维搜索 (Line Search)
 - 停止检验 (Stop Check)
 - 最常用的停止规则 (Stop Criterion) : $|x_{k+1} - x_k| \leq \varepsilon$

ε 是一个给定的大于零的常数



算法

- 怎样画算法的流程图
(Flowchart) ?



算法

- 一维搜索法；
- 在确定下降方向后，需要进行线性搜索，以便确定下降方向上的最优点，作为下一个迭代点；
- 一维搜索问题的常用求解算法：
 - 二分法
 - 黄金分割法
 - 牛顿法





二分法

□ 假设

$z(x)$ 是凸函数，且在区间 $[a, b]$ 内是连续可微函数。

□ 原理

求其导函数 $z'(x)$ 在区间 $[a, b]$ 内的零点（根），即
 $z'(x)=0$ with $a \leq x \leq b$



二分法

□ 算法步骤

$$(b_{k+1} - a_{k+1}) = 0.5 * (b_k - a_k)$$

Step 0: 给定一个初始解

$[a_0, b_0] \subseteq [a, b]$ 其中 $x^* \in [a, b]$, $z'(a_0) < 0, z'(b_0) > 0$

令 $k=0$


Step 1: 如果 $b_k - a_k \leq \varepsilon$, 则停止, 得到一个极小值 $x^* = (b_k + a_k)/2$
否则, 转入 Step 2

Step 2: 令 $x_k = (b_k + a_k)/2$

如果 $z'(x_k) \geq 0$, 则 $b_{k+1} = x_k, a_{k+1} = a_k$

如果 $z'(x_k) < 0$, 则 $a_{k+1} = x_k, b_{k+1} = b_k$

令 $k=k+1$, 并返回 Step 1.



二分法

●例1

用二分法解如下非线性规划问题：

$$\min z(x) = \sin x$$

$$s.t. \ 3 \leq x \leq 6$$

解：

因为： $z'(x) = \cos x, a_0 = 3, b_0 = 6, x_0 = 4.5$

所以： $z'(3) = -0.99 < 0, z'(6) = 0.96 > 0, z'(x_0) = -0.2108$

因此： $a_1 = 4.5, b_1 = 6, x_1 = 5.25$

重复上述过程，迭代过程如下表所示：



二分法

□ 例1

二分法的迭代过程

k	a_k	b_k	x_k	$z'(x_k)$	$z'(a_k)$	$z'(b_k)$
0	3	6	4.5	-0.2108	-0.99	0.96017
1	4.5	6	5.25	0.51209	-0.2108	0.96017
2	4.5	5.25	4.875	0.1619	-0.2108	0.51209
3	4.5	4.875	4.6875	-0.0249	-0.2108	0.1619
4	4.6875	4.875	4.78125	0.06881	-0.0249	0.1619
5	4.6875	4.78125	4.73438	0.02198	-0.0249	0.06881
6	4.6875	4.73475	4.71113	-0.0013	-0.0249	0.02236



关于二分法的讨论

- 在 step 2, 为什么我们不考虑 $z(x_k)=0$ 的情况?
 - 由于问题的结构和数值误差 (problem structure and numerical errors), $z(x_k)=0$ 的可能性是很低的
- 输出应该选哪一个?
 - $(a_k+b_k)/2$, or a_k or b_k
 - 这不重要, 因为可容忍的误差 ε 一般是很小的。



关于二分法的讨论

- 在停止条件里，如何确定 ε ?
 - ε 的取值较大时，将使算法的收敛速度很快，但是精度较低。
因此 ε 是在效率和精度的权衡下确定的；
 - 例如，如果 x 表示零售市场的单位价格，那么 $\varepsilon = 1$ 分就是可接受的。
- 其他常用的停止条件有哪些？
 - 要求算法在一个给定的迭代次数后停止；
 - 要求算法在一个给定的CPU时间后停止。



结论

- 二分法是用来求解凸的连续可微函数？对吗？
 - 如果问题是不可微的，二分法就是无效的
- 而黄金分割法不需要原问题是可微的，而且不要求该问题是凸函数。




黄金分割法



$$\min_{a \leq x \leq b} z(x)$$

Example:

$$\min_{2 \leq x \leq 4} z(x) = (x-1)^2 + 1$$



黄金分割法



牛顿法

●一元非线性规划问题： $\min_{a \leq x \leq b} f(x)$

$f: R^1 \rightarrow R^1$ 在可行域 $[a, b]$ 内具有连续的一阶和二阶导函数

●基本原理

因为 $f(x)$ 在 $[a, b]$ 上连续可微，所以原函数的最小值问题等价于求 $f'(x) = 0$

设在区间 $[a, b]$ 中经过 k 次迭代所得到的变量值为 x_k

过点 $(x_k, f'(x_k))$ 作曲线 $y = f'(x)$ 的切线，其方程是


$$y - f'(x_k) = f''(x_k)(x - x_k)$$

然后用这条切线与横轴交点的横坐标 x_{k+1} 作为根的新的近似点。在此点

处 $y = 0$ ，从而得到：

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad \text{——此即为牛顿法的迭代公式}$$






$$y - y^n = k^n (x - x^n)$$
$$x = x^n - \frac{y^n}{k^n}$$

牛顿法

● 基本原理的几何表示



牛顿法

● 算法步骤

已知 $f(x), f'(x)$ 表达式, 停止条件 ε


(a) 确定初始搜索区间 $[a, b]$, 要求 $f'(a) < 0, f'(b) > 0$.

(b) 选定 x_0 ;

(c) 计算 $x = x_0 - f'(x_0) / f''(x_0)$

(d) 若 $|x - x_0| \geq \varepsilon$, 则 $x_0 = x$, 转入 (c) ;
否则转入 (e) ;

(e) 输出 $x, f(x)$, 结束。



梯度下降法

梯度下降法


□ 问题

确定可微函数 $z(x)$, $x \in R^n$ 的局部极小值点.

x^* 如果满足 $z(x^*) \leq z(x), \forall x \in R^n$, 则 x^* 是 $z(x)$ 的一个 (全局) 极小值点.

如果存在 $\varepsilon > 0$, x^* 满足 $z(x^*) \leq z(x), \forall x \in R^n$ 和 $\|x - x^*\| < \varepsilon$, 则 x^* 是 $z(x)$ 的局部极小值点


.



梯度下降法

▣ 下降方向法的基本原理


- 每次沿着可行下降方向，从一个点移动到另一个点，来使目标函数值减小



梯度下降法

▣ 下降方向法的基本原理

- Step 0: 选择初始点 $x^{(0)}$
- Step 1: 检查停止条件
- Step 2: 确定可行下降方向 $d^{(k)}$
- Step 3: 确定与方向 $d^{(k)}$ 相关的最优步长 $\alpha^{(k)}$
- Step 4: 令 $x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)}$



梯度下降法

- 最速下降法/梯度下降法
- 基本原理是用负梯度方向

$$\nabla_z(x^{(k)}) := \begin{pmatrix} \frac{\partial z}{\partial x_1^{(k)}} \\ \frac{\partial z}{\partial x_2^{(k)}} \\ \vdots \\ \frac{\partial z}{\partial x_n^{(k)}} \end{pmatrix}$$



梯度下降法

▣ 梯度下降法步骤

Step 0: 选择初始点 $x^{(0)}$, 并令 $k = 0$, 设定 $\varepsilon > 0$

Step 1: 如果 $|\nabla z(x^{(k)})| < \varepsilon$, 则停止. 否则, 转入Step 2

Step 2: 令 $d^{(k)} := -\nabla z(x^{(k)})$, 求解一元最小化问题:

$$\min_{\substack{\alpha \geq 0 \\ x^{(k)} + \alpha d^{(k)} \in \Omega}} z(x^{(k)} + \alpha d^{(k)}) \text{ 来确定 } \alpha^{(k)}$$

Step 3: 令 $x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)}$, 并令 $k = k + 1$, 返回 Step 1.



梯度下降法

▣ 梯度下降法步骤

- 在Step 0, 一般情况下, 最好选择接近局部极小值点的初始点 (例如, 用启发式算法的最优解来确定初始解);
- 在Step 1, 有多种停止条件;
- Step 2的子问题是线性搜索。这比原来的问题更容易求解, 在这里我们可以用KKT条件、二分法或黄金分割法来求解。



梯度下降法

□ 例

$$\min_{x \in \mathbb{R}^2} z(x) = (x_1 - 2)^2 + 10(x_2 - 2)^2$$

- 梯度 $\nabla z(x) = (2x_1 - 4, 20x_2 - 40)^T$
- 线性搜索

$$f(\alpha) = z(x^{(k)} - \alpha \nabla z(x^{(k)})) = (x_1 + \alpha(4 - 2x_1^{(k)}) - 2)^2 + 10(x_2^{(k)} + \alpha(40 - 20x_2^{(k)}) - 2)^2$$

✓ 令 $f'(\alpha) = 0$, 可得:

$$0 \leq \alpha_k = \frac{(4 - 2x_1^{(k)})^2 + (40 - 20x_2^{(k)})^2}{2(4 - 2x_1^{(k)})^2 + 20(40 - 20x_2^{(k)})^2}$$



梯度下降法

□ 例

- 迭代方案 (2 iterations)

k	$\mathbf{x}^{(k)}$	$\mathbf{d}^{(k)}$	$ \mathbf{d}^{(k)} $	$\alpha^{(k)}$	$z(\mathbf{x}^{(k)})$
0	$(-4, -3)$	$(12, 100)$	100.7	0.051	286
1	$(-3.392, 2.065)$	$(10.784, -1.294)$	10.9	0.443	29.118
2	$(1.389, 1.491)$				



梯度下降法

□ 讨论

- 当 $z(x)$ 是凸函数时, 梯度下降法将在一个全局最优解处停止
- 由于梯度下降法 “zigzaging” 的性质, 该方法收敛速度慢
 - 二次函数
 - 罗森布鲁克函数 (Rosenbrock function)


$$f(x_1, x_2) = (1 - x_1)^2 + 100[x_2 - (x_1)^2]^2$$



梯度下降法

□ 讨论


• Zigzaging



梯度下降法

□ 讨论

- 罗森布鲁克函数（Rosenbrock function）



Frank-Wolfe算法

Frank-Wolfe 算法

□ Frank Wolfe Algorithm (convex combination algorithm)

求解下面凸规划问题的最优解：

$$\begin{aligned} & \min_x f(x) \\ & \text{subject to} \\ & g(x) \leq 0 \\ & h(x) = 0 \end{aligned}$$

- Frank, M. and Wolfe (1956) An algorithm for quadratic programming. Naval Research Logistics quarterly Research, Vol. 14, pp. 43-53.



Frank-Wolfe 算法

□ 算法步骤



Step 0: 选择一个初始可行点 $x^{(0)}$ ，并令 $k=0$

Step 1: 确定可行下降方向 $d^{(k)}=y^{(k)}-x^{(k)}$ ，其中 $y^{(k)}$ 是如下问题的最优解:

$$\begin{aligned} & \min_y y^T \nabla f(x^{(k)}) \\ & \text{subject to} \\ & g(y) \leq 0 \\ & h(y) = 0 \end{aligned}$$



$$\begin{aligned} \max (& \\ = \min (& \\ = \min & \\ = \min & \end{aligned}$$



Frank-Wolfe 算法

Step 2: 确定 α_k : 通过一维搜索法求解如下一元最小化问题的最优解来确定 α_k

$$\min_{0 \leq \alpha \leq 1} f\left(x^{(k)} + \alpha(y^{(k)} - x^{(k)})\right)$$

Step 3: 令 $x^{(k+1)} = x^{(k)} + \alpha_k(y^{(k)} - x^{(k)})$ 和 $k=k+1$

Step 4: 如果 $\left| \sqrt{\sum_{i=1}^n \left[\left(x_i^{(k)} - x_i^{(k-1)} \right)^2 \right]} \right| \leq \varepsilon$, 则停止迭代; 否则, 转到 Step 1



Frank-Wolfe 算法

□ 例

用F-W算法求解下面最小化问题的最优解，停止条件为 $\varepsilon=0.01$ ，初始解为 $\mathbf{x}^{(0)}=(0,0)$


$$\min f(\mathbf{x}) = (x_1 - 2)^2 + (x_2 - 3)^2$$

subject to

$$x_1 + x_2 \leq 2$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



Frank-Wolfe 算法

迭代 1 ($k=0$)

$$\nabla f(x^{(0)}) = (-4, -6)^T$$

(1) 解下面的线性规划问题确定 $y^{(0)}$:

$$\min z(y) = -4y_1 - 6y_2$$

subject

to


$$y_1 + y_2 \leq 2$$

$$y_1 \geq 0$$

$$y_2 \geq 0$$

(2) 检查停止条件:

$$\left| \sum_{i=1}^n \left[\left(\partial f(x^{(0)}) / \partial x_i \right) (y_i^{(0)} - x_i^{(0)}) \right] \right| = \left| [-4 \times (0 - 0) + (-6)(2 - 0)] \right| > 0.01$$



Frank-Wolfe 算法


(3) 通过二分法求下面一元最优化问题的最优解 α_0 :

$$x^{(0)} + \alpha(y^{(0)} - x^{(0)}) = (0, 0)^T + \alpha[(0, 2)^T - (0, 0)^T] = (0, 2\alpha)^T$$

$$\min_{0 \leq \alpha \leq 1} f(x^{(0)} + \alpha(y^{(0)} - x^{(0)})) = (0 - 2)^2 + (2\alpha - 3)^2 \longrightarrow \alpha_0 = 1$$

(4) 更新

$$\begin{aligned} x^{(1)} &= x^{(0)} + \alpha_0(y^{(0)} - x^{(0)}) \\ &= \begin{pmatrix} 0 + 1 \times (0 - 0) \\ 0 + 1 \times (2 - 0) \end{pmatrix} \\ &= \begin{pmatrix} 0 \\ 2 \end{pmatrix} \end{aligned}$$



Frank-Wolfe 算法

迭代 2 (k=1)

$$\nabla f(x^{(1)}) = (-4, -2)^T$$

$$x^{(1)} = (0, 2)$$

(1) 解下面的线性规划问题确定 $y^{(1)}$:

$$\min z(y) = -4y_1 - 2y_2$$


$$y_1 \geq 0$$

$$y_2 \geq 0$$

$$y_1 + y_2 \leq 2$$



$$y^{(1)} = (2, 0)$$



(2) 检查停止条件:

$$\left| \sum_{i=1}^n \left[\left(\partial f(x^{(1)}) / \partial x_i \right) (y_i^{(1)} - x_i^{(1)}) \right] \right| = \left| [-4 \times (2 - 0) + (-2)(0 - 2)] \right| > 0.01$$

Frank-Wolfe 算法

(3)通过二分法求下面一元最优化问题的最优解 α_0 :

$$\min_{0 \leq \alpha \leq 1} f\left(x^{(1)} + \alpha(y^{(1)} - x^{(1)})\right) = (2\alpha - 2)^2 + (-2\alpha - 1)^2 \Rightarrow \alpha_1 = 0.25$$

(4)更新

$$\begin{aligned} x^{(2)} &= x^{(1)} + \alpha_1(y^{(1)} - x^{(1)}) \\ &= \begin{pmatrix} 0 + 0.25 \times (2 - 0) \\ 2 + 0.25 \times (0 - 2) \end{pmatrix} \\ &= \begin{pmatrix} 0.5 \\ 1.5 \end{pmatrix} \end{aligned}$$

