

交通大数据

支持向量机

- 刘志远教授
- zhiyuanl@seu.edu.cn



支持向量机

□ 学习目标

- 了解支持向量机的基本概念
- 掌握线性可分支持向量机模型
- 掌握软间隔支持向量机模型
- 理解非线性支持向量机中的核函数
- 介绍序列最小优化算法（阅读内容）



支持向量机


□ 学习目标

- **了解支持向量机的基本概念**
- 掌握线性可分支持向量机模型
- 掌握软间隔支持向量机模型
- 理解非线性支持向量机中的核函数
- 介绍序列最小优化算法（阅读内容）




基本概念

- 如何将下面的数据分成两类？






基本概念

- 如何将下面的数据分成两类？
- 是否有更符合直觉的方法？






基本概念

- 下列数据能否用一条直线划分开来？
- **线性可分 (linearly separable)** , 硬间隔、软间隔
- **线性不可分**



基本概念


- **不同维度**空间下的线性可分
- 对于 n 维数据, 可以使用 $n - 1$ 维的超平面进行分隔

 $\mathbb{R}^1$  $\mathbb{R}^2$  $\mathbb{R}^3$

超平面 $\mathbf{w}^T \mathbf{x} + b = 0$

基本概念


- 哪一条是**最优分隔超平面**？为什么？



基本概念

- 超平面方程: $\mathbf{w}^\top \mathbf{x} + b = 0$

支持向量: 距离超平面最近的样本



直观上讲，**支持向量机**是一种通过构建超平面来实现分类决策的机器学习模型。



基本概念


- 对于一个线性可分的数据集 D ，总能找到一组参数 $\mathbf{w}$ 和 b ，对于任意样本 $(\mathbf{x}_i, y_i) \in D$ 都满足

$$\begin{cases} \mathbf{w}^\top \mathbf{x}_i + b \geq +1, & y_i = +1; \\ \mathbf{w}^\top \mathbf{x}_i + b \leq -1, & y_i = -1. \end{cases}$$

- 这一条件可简化为：

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$$

- 这一边界条件构成区域的宽度被称为**间隔**



基本概念


任意样本 $\mathbf{x}$ 到超平面的距离： $\delta = \frac{|\mathbf{w}^\top \mathbf{x} + b|}{\|\mathbf{w}\|}$

- 根据点到直线距离公式，容易推出间隔大小 γ

$$\delta = \frac{|\mathbf{w}^\top \mathbf{x} + b|}{\|\mathbf{w}\|}$$

↓

$$\gamma = \frac{|+1|}{\|\mathbf{w}\|} + \frac{|-1|}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$



距离公式的推导

给定点 x_1 , 求其到超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的距离 δ


任取平面上一点 x_0 , 那么 x_1 到平面的距离等于向量 $(x_1 - x_0)$ 在平面法方向上的投影。根据平面方程可知法方向为: $\bar{\mathbf{w}}/\|\mathbf{w}\|$

因此, 点 x_1 到平面距离为:

$$\delta = \frac{(x_1 - x_0) \cdot \mathbf{w}}{\|\mathbf{w}\|} = \frac{\mathbf{w}^T x_1 - \mathbf{w}^T x_0}{\|\mathbf{w}\|}$$

因为点 x_0 在平面上, 所以 $\mathbf{w}^T x_0 + b = 0$, 所以:

$$\delta = \frac{\mathbf{w}^T x_1 - \mathbf{w}^T x_0}{\|\mathbf{w}\|} = \frac{\mathbf{w}^T x_1 + b}{\|\mathbf{w}\|}$$



支持向量机

□ 学习目标

- 了解支持向量机的基本概念
- **掌握线性可分支持向量机模型**
- 掌握软间隔支持向量机模型
- 理解非线性支持向量机中的核函数
- 介绍序列最小优化算法（阅读内容）



线性可分支持向量机

□ 支持向量机基本型

- 应用场景：线性可分的数据
- 优化目标：找到具有最大**间隔**的分隔超平面

$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|}$$

$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i=1, 2, \dots, m.$$

- 该模型等价于

$$\min_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2}$$

$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i=1, 2, \dots, m.$$

线性约束下的
凸二次规划



线性可分支持向量机

□ 支持向量机基本型

- 模型存在哪些问题？

$$\min_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2}$$

$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m.$$

- 不等式约束较为复杂（数量太多），求解难度大



线性可分支持向量机

□ 线性可分支持向量机的对偶问题

- 拉格朗日乘子: $\boldsymbol{\alpha} := (\alpha_1; \alpha_2; \dots; \alpha_m)$

- 拉格朗日函数: $\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i [1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)]$

- KKT条件:

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*) = \mathbf{0}$$

$$\nabla_b \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*) = 0$$

$$\boldsymbol{\alpha}^* \geq \mathbf{0}$$

$$\alpha_i^* [1 - y_i(\mathbf{w}^{*,\top} \mathbf{x}_i^* + b)] = 0, i = 1, 2, \dots, m$$

$$1 - y_i(\mathbf{w}^{*,\top} \mathbf{x}_i^* + b) \leq 0, i = 1, 2, \dots, m$$

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$$

$$0 = \sum_{i=1}^m \alpha_i^* y_i$$

- 进而, 化简拉格朗日函数: $\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$

教材书: 141页的详细推导



线性可分支持向量机

□ 线性可分支持向量机的对偶问题

● 对偶问题：

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j$$

$$\begin{aligned} \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

● 模型存在哪些问题？

- 对偶变量数量=样本数，求解难度大
- 解决方法: Sequential Minimal Optimization 序列最小优化算法
- (自学内容，看教材书7.5节)



线性可分支持向量机

□ 线性可分支持向量机的对偶问题

● 如何从对偶问题的解得到原问题的解？

● 由KKT条件可得：
$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$$

此时对 α_i^* 进行讨论：

① $\alpha_i^* = 0$ $\Rightarrow$ 对 $\mathbf{w}^*$ 没有影响 $\Rightarrow$ 若 $\alpha_i^* = 0$, 样本 i 不是SV

② $y_i(\mathbf{w}^{*\top} \mathbf{x}_i + b) \geq 1$ $\Rightarrow$ 对 $\mathbf{w}^*$ 有影响 $\Rightarrow$ 若 $y_i(\mathbf{w}^{*\top} \mathbf{x}_i + b) \geq 1$ 样本 i 是SV



线性可分支持向量机

□ 线性可分支持向量机的对偶问题

- 如何从对偶问题的解得到原问题的解？

对于互补松弛条件, 有 $\alpha_i^*[y_i(\mathbf{w}^{*\top}\mathbf{x}_i + b^*) - 1] = 0 \rightarrow$ 必有 $\alpha_i^* = 0$ 或 $y_i(\mathbf{w}^{*\top}\mathbf{x}_i + b^*) = 1$

$y_i(\mathbf{w}^{*\top}\mathbf{x}_i + b^*) = 1 \rightarrow$ 样本 $(\mathbf{x}_i, y_i)$ 是**支持向量**!

- 将计算过的 $\mathbf{w}^*$ 代入上式可得:

$$b^* = \frac{1}{y_i} - \sum_{j=1}^m \alpha_j^* y_j \mathbf{x}_j^\top \mathbf{x}_i = y_i - \sum_{j=1}^m \alpha_j^* y_j \mathbf{x}_j^\top \mathbf{x}_i$$

若 $\alpha_i^* = 0 \Rightarrow$ 对 b^* 也没有影响

y_i 的取值为1或者-1

支持向量 $\Leftrightarrow \alpha_i^* > 0$



线性可分支持向量机

□ 试一试


- 使用线性可分支持向量机对案例数据进行分类。

1. 生成案例数据

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
```

```
X, y = make_classification(
    n_samples=100, n_features=2,
    n_redundant=0, n_informative=2,
    random_state=1, n_clusters_per_class=1
)
rng = np.random.RandomState(2)
X += rng.uniform(size=X.shape)

plt.figure(figsize=(5, 5))
sns.scatterplot(
    x=X[:,0], y=X[:,1], hue=y, legend='full')
plt.show()
```



线性可分支持向量机

□ 试一试

- 使用线性可分支持向量机对案例数据进行分类。

2. 训练模型

```
from sklearn.preprocessing import StandardScaler  
from sklearn.svm import SVC
```

```
# 数据标准化
```

```
X_ = StandardScaler().fit_transform(X)  
data = X_, y
```

```
# 构建线性可分支持向量机，训练模型
```

```
clf = SVC(C=1e9, kernel='linear', random_state=3)  
clf.fit(X_, y)
```



线性可分支持向量机

□ 试一试

- 使用线性可分支持向量机对案例数据进行分类。

3. 查看分类结果

```
def plot_predicted_proba(data, clf, h=0.02):  
    X, y = data  
  
    x_min, x_max = X[:, 0].min() - .5, X[:, 0].max() + .5  
    y_min, y_max = X[:, 1].min() - .5, X[:, 1].max() + .5  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),  
                          np.arange(y_min, y_max, h))  
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)  
  
    plt.figure(figsize=(5, 5))  
    plt.contourf(xx, yy, Z, cmap=plt.cm.RdBu, alpha=.8)  
    sns.scatterplot(x=X[:, 0], y=X[:, 1], hue=y, legend='full')  
    plt.xlim(x_min, x_max)  
    plt.ylim(y_min, y_max)  
    plt.show()
```

```
plot_predicted_proba(data, clf)
```




线性可分支持向量机

□ 试一试

- 使用线性可分支持向量机对案例数据进行分类。

3. 查看分类结果



支持向量机

□ 学习目标


- 了解支持向量机的基本概念
- 掌握线性可分支持向量机模型
- **掌握软间隔支持向量机模型**
- 理解非线性支持向量机中的核函数
- 介绍序列最小优化算法（阅读内容）



软间隔线性支持向量机

□ 硬间隔与软间隔

- 下面的分隔方式合理吗？




这很可能是数据**噪声**！



软间隔线性支持向量机

□ 硬间隔与软间隔

- 下面的分隔方式合理吗？



软间隔线性支持向量机

□ 硬间隔与软间隔

- 支持向量机基本型的约束过于严格：

- 所有样本必须在间隔**外侧**


$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

- 可将此约束放松：

- 允许样本在间隔**内侧**

- 允许样本分类**出错**

- 对出错的样本增加**惩罚**即可



软间隔线性支持向量机

□ 硬间隔与软间隔

● 改进数学模型：

- 丢弃原先的约束条件，允许分类出错
- 允许部分样本被错误划分的条件为软间隔 (soft margin)


● 此时如何衡量模型好坏？

改造**目标函数**！

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell(y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$

超参数 $C > 0$ ，**权衡**分类错误的影响大小
(当 $C \rightarrow +\infty$ ，退化为硬间隔支持向量机)

损失函数，度量分类的**错误程度**


$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$$



软间隔线性支持向量机

□ 硬间隔与软间隔

- 如何选择损失函数?
- 直接的想法：对错误分类加以**惩罚**



能否继续改进?

$$\ell_{0-1}(z) = \begin{cases} 1, & z < 0; \\ 0, & z \geq 0. \end{cases}$$

其中 $z = y_i(\mathbf{w}^T \mathbf{x} + b)$

↓ ↓

真实标签 预测值

- 真实值与预测值**同号**, 分类正确, 不惩罚;
- 真实值与预测值**异号**, 分类错误, 进行惩罚


软间隔线性支持向量机

□ 硬间隔与软间隔

● 0-1损失函数

$$\ell_{0-1}(z) = \begin{cases} 1, & z < 0; \\ 0, & z \geq 0. \end{cases}$$


- 不连续
- 非凸



软间隔线性支持向量机

□ 硬间隔与软间隔

- hinge损失函数!
- 进一步考虑样本分类的**错误程度**，离分隔超平面越远，错误越离谱




软间隔线性支持向量机

□ 硬间隔与软间隔

● hinge损失函数

$$\ell_h(z) = \max(0, 1 - z)$$



- 连续
- 凸性
- 在 $z=1$ 处不可微!

软间隔线性支持向量机

□ 硬间隔与软间隔

- 使用hinge损失函数的线性支持向量机被称为软间隔线性支持向量机
- 数学模型如下：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$

- 如何解决目标函数在 $z = 1$ 不可微的问题？
 - 引入松弛变量，对模型进行改造（一个重要的技巧）



软间隔线性支持向量机

□ 硬间隔与软间隔

- 改进的数学模型如下：

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$\max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$



$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i,$$

$$\text{松弛变量} \longleftarrow \xi_i \geq 0, \quad i = 1, 2, \dots, m.$$

$$\text{对比 } \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 又出现了**复杂约束**

- 如何解决？

- 找对偶问题！

- 再次使用**拉格朗日乘子法**构造二次规划问题的对偶问题

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

s.t.

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \\ \xi_i \geq 0, \quad i = 1, 2, \dots, m.$$

试一试

写出该问题的拉格朗日函数。



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 对偶变量: α, μ
- 不等式约束1: $y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, m$ α
- 不等式约束2: $\xi_i \geq 0, i = 1, 2, \dots, m$ μ
- 拉格朗日函数:

$$\mathcal{L}(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(\mathbf{w}^\top \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$

再试一试

写出软间隔线性支持向量机的KKT条件。



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● (1) 基本约束

① 原问题的可行约束

$$\xi_i^* \geq 0, i = 1, 2, \dots, m$$

$$y_i(\mathbf{w}^{*,\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* \geq 0, i = 1, 2, \dots, m$$

② 对偶变量的非负约束

$$\alpha_i^* \geq 0, \mu_i^* \geq 0, i = 1, 2, \dots, m$$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● (2) 一阶偏导条件 (KKT等式)

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}, \boldsymbol{\xi}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i (\mathbf{w}^\top \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$



$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \mathbf{w}^* - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i = \mathbf{0}$$

$$\nabla_b \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \sum_{i=1}^m \alpha_i^* y_i = 0$$

$$\nabla_{\xi} \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = C - \boldsymbol{\alpha}^* - \boldsymbol{\mu}^* = \mathbf{0}$$

软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● (3) 互补松弛条件

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}, \boldsymbol{\xi}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i (\mathbf{w}^\top \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$



$$\mu_i^* \xi_i^* = 0, i = 1, 2, \dots, m$$

$$\alpha_i^* [y_i (\mathbf{w}^{*,\top} \mathbf{x}_i + b^*) - 1 + \xi_i^*] = 0, i = 1, 2, \dots, m$$

软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● KKT条件:

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \mathbf{w}^* - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i = \mathbf{0}$$

$$\nabla_b \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \sum_{i=1}^m \alpha_i^* y_i = 0$$

$$\nabla_{\boldsymbol{\xi}} \mathcal{L}(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \mathbf{C} - \boldsymbol{\alpha}^* - \boldsymbol{\mu}^* = \mathbf{0}$$

$$\alpha_i^* \geq 0, \xi_i^* \geq 0, \mu_i^* \geq 0, i=1, 2, \dots, m$$

$$y_i (\mathbf{w}^{*,\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* \geq 0, i=1, 2, \dots, m$$

$$\mu_i^* \xi_i^* = 0, i=1, 2, \dots, m$$

$$\alpha_i^* [y_i (\mathbf{w}^{*,\top} \mathbf{x}_i + b^*) - 1 + \xi_i^*] = 0, i=1, 2, \dots, m$$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 拉格朗日对偶函数：

$$g(\alpha, \mu) = \inf_{\mathbf{w}, b, \xi} \mathcal{L}(\mathbf{w}, b, \alpha, \xi, \mu)$$

- 根据一阶偏导最优性条件，

$$\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^*, b^*, \alpha^*, \xi^*, \mu^*) = \mathbf{w}^* - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i = \mathbf{0}$$

$$\nabla_b \mathcal{L}(\mathbf{w}^*, b^*, \alpha^*, \xi^*, \mu^*) = \sum_{i=1}^m \alpha_i^* y_i = 0$$

$$\nabla_{\xi} \mathcal{L}(\mathbf{w}^*, b^*, \alpha^*, \xi^*, \mu^*) = C - \alpha^* - \mu^* = 0$$

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$$

$$0 = \sum_{i=1}^m \alpha_i^* y_i$$

$$\mu_i = C - \alpha_i \geq 0$$

教材书：144页的详细推导



代入拉格朗日对偶函数并化简

$$g(\alpha, \mu) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j$$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● 拉格朗日对偶问题:

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$

$$\begin{aligned} \mu_i = C - \alpha_i &\geq 0 \\ \alpha_i &\geq 0 \end{aligned}$$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 根据互补松弛条件:

$$\alpha_i^* [y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^*] = 0, i = 1, 2, \dots, m$$



支持向量 $\Leftrightarrow \alpha_i^* > 0$

① $\alpha_i^* = 0$

$$\boxed{\mu_i = C - \alpha_i \geq 0} \Rightarrow \mu_i = C > 0$$

$$\boxed{\mu_i^* \xi_i^* = 0} \Rightarrow \xi_i^* = \max(0, 1 - y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*)) = 0 \Rightarrow y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) \geq 1$$

hinge损失为0

样本可能在**间隔边界上** $y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) = 1$
也可能在边界外侧 $y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) > 1$



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 根据互补松弛条件:

$$\alpha_i^* [y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^*] = 0, i = 1, 2, \dots, m$$



支持向量 $\Leftrightarrow \alpha_i^* > 0$

$$\textcircled{2} \quad 0 < \alpha_i^* < C \quad \Rightarrow \quad y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* = 0$$

$$\boxed{\mu_i = C - \alpha_i^* \geq 0} \quad \Rightarrow \quad \mu_i > 0$$

$$\boxed{\mu_i^* \xi_i^* = 0} \quad \Rightarrow \quad \xi_i^* = \max(0, 1 - y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*)) = 0 \quad \Rightarrow \quad y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 = 0$$

hinge损失为0

样本恰在**间隔边界**上



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

- 根据互补松弛条件:

$$\alpha_i^* [y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^*] = 0, i = 1, 2, \dots, m$$



支持向量 $\Leftrightarrow \alpha_i^* > 0$

$$\textcircled{3} \quad \alpha_i^* = C \quad \Rightarrow \quad y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* = 0$$

$$\boxed{\mu_i = C - \alpha_i \geq 0} \quad \Rightarrow \quad \mu_i = 0 \quad \boxed{\mu_i^* \xi_i^* = 0} \quad \Rightarrow \quad \xi_i^* \geq 0$$

若 $0 \leq \xi_i^* < 1 \Rightarrow 0 < y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* \leq 1$ 分类正确, 样本在**间隔边界**与**分隔超平面**之间

若 $\xi_i^* = 1 \Rightarrow y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* = 0$ 样本恰在**分隔超平面**上

若 $\xi_i^* > 1 \Rightarrow y_i (\mathbf{w}^{*\top} \mathbf{x}_i + b^*) - 1 + \xi_i^* < 0$ 分类错误, 样本在**分隔超平面**分类错误的一侧



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题

● 软间隔支持向量总结：

$$(1) \quad \alpha_i^* = 0, \xi_i^* = 0, y_i(\mathbf{w}^{*\top} \mathbf{x}_i + b^*) \geq 1$$


非支持向量, hinge损失=0

$$(2) \quad \alpha_i^* = 0, \xi_i^* = 0, y_i(\mathbf{w}^{*\top} \mathbf{x}_i + b^*) \geq 1$$

支持向量, hinge损失=0

$$(3) \quad \alpha_i^* = 0, \xi_i^* = 0, y_i(\mathbf{w}^{*\top} \mathbf{x}_i + b^*) \geq 1$$

支持向量, hinge损失 ≥ 0



软间隔线性支持向量机

□ 软间隔线性支持向量机的对偶问题


● 软间隔支持向量与硬间隔支持向量的区别:

硬间隔

- 支持向量出现在间隔的**边界上**

软间隔

- 支持向量可能在间隔**边界与分隔超平面**之间
- 也可能在分隔超平面**分类错误的一侧**



软间隔线性支持向量机

□ 试一试


- 使用软间隔线性支持向量机对案例数据进行分类。

1. 生成案例数据

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
```

```
X, y = make_classification(
    n_samples=100, n_features=2,
    n_redundant=0, n_informative=2,
    random_state=1, n_clusters_per_class=1
)
rng = np.random.RandomState(2)
X += rng.uniform(size=X.shape)

plt.figure(figsize=(5, 5))
sns.scatterplot(
    x=X[:,0], y=X[:,1], hue=y, legend='full')
plt.show()
```



软间隔线性支持向量机

□ 试一试

- 使用软间隔线性支持向量机对案例数据进行分类。

2. 训练模型

```
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
```

数据标准化

```
X_ = StandardScaler().fit_transform(X)
data = X_, y
```

构建软间隔线性支持向量机，训练模型

```
clf = SVC(C=1, kernel='linear', random_state=3)
clf.fit(X_, y)
```

考虑了参数C!



软间隔线性支持向量机

□ 试一试

- 使用软间隔线性支持向量机对案例数据进行分类。

3. 查看分类结果

```
def plot_predicted_proba(data, clf, h=0.02):  
    X, y = data  
  
    x_min, x_max = X[:, 0].min() - .5, X[:, 0].max() + .5  
    y_min, y_max = X[:, 1].min() - .5, X[:, 1].max() + .5  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),  
                          np.arange(y_min, y_max, h))  
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)  
  
    plt.figure(figsize=(5, 5))  
    plt.contourf(xx, yy, Z, cmap=plt.cm.RdBu, alpha=.8)  
    sns.scatterplot(x=X[:, 0], y=X[:, 1], hue=y, legend='full')  
    plt.xlim(x_min, x_max)  
    plt.ylim(y_min, y_max)  
    plt.show()
```

```
plot_predicted_proba(data, clf)
```





软间隔线性支持向量机

□ 试一试

- 使用软间隔线性支持向量机对案例数据进行分类。

3. 查看分类结果



对于线性可分且无明显噪声的数据，软间隔与硬间隔SVM的结果区别不大

软间隔线性支持向量机

□ 试一试


- 使用软间隔线性支持向量机对案例数据进行分类。

尝试更换一组
训练数据

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
```

```
X, y = make_classification(
    n_samples=100, n_features=2,
    n_redundant=0, n_informative=2,
    random_state=1, n_clusters_per_class=1
)
rng = np.random.RandomState(2)
X += rng.uniform(size=X.shape) * 2

plt.figure(figsize=(5, 5))
sns.scatterplot(
    x=X[:,0], y=X[:,1], hue=y, legend='full')
plt.show()
```



线性不可分!




软间隔线性支持向量机

□ 试一试

- 使用软间隔线性支持向量机对案例数据进行分类。

尝试更换一组
训练数据



- 线性可分支持向量机无法训练
- 软间隔线性支持向量机可以给出合理结果

支持向量机

□ 学习目标



- 了解支持向量机的基本概念
- 掌握线性可分支持向量机模型
- 掌握软间隔支持向量机模型
- **理解非线性支持向量机中的核函数**
- 介绍序列最小优化算法（阅读内容）



非线性支持向量机

□ 核技巧 (kernel trick)


- 线性支持向量机能够处理的问题:



非线性支持向量机

□ 核技巧

- 线性支持向量机不能处理的问题:



如何处理?

非线性支持向量机


- 核技巧
- 空间扭曲!



非线性支持向量机

□ 核技巧


- 构造映射函数 $\phi(\cdot): \mathbb{R}^s \rightarrow \mathbb{R}^t$ 对原特征空间做变换



非线性支持向量机

□ 核技巧

- 原空间和变换后空间的维度可不一致
- 可在更高维度的空间让数据变成线性可分



非线性支持向量机

□ 核技巧

- 对数据变换后，可使用线性支持向量机求解

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$\begin{aligned} \text{s.t.} \quad & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$



非线性支持向量机

□ 核技巧

● 对偶问题

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$

输入样本在新特征空间中的**内积**!


$$\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$$



非线性支持向量机

□ 核技巧

- 使用映射函数 $\phi(\cdot)$ 并不能一劳永逸地解决所有问题。
 - 输入数据维度较低时, $\phi(\cdot)$ 容易确定
 - **高维**输入**难以找到**合适的 $\phi(\cdot)$
 - **高维**空间下**计算量**巨大



非线性支持向量机

□ 核技巧

- 重新观察非线性支持向量机的对偶问题：
 - 是否有必要知道确切的映射函数 $\phi(\cdot)$?

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^{\top} \phi(\mathbf{x}_j)$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$



非线性支持向量机

□ 核技巧

- 替代: $\kappa(x_i, x_j) = \phi(x_i)^\top \phi(x_j)$
 - 跳过先映射、再求内积的过程

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$




非线性支持向量机

□ 核技巧

- 类似地，可以改写分隔超平面的方程：

$$\begin{aligned} f(\mathbf{x}) &= \mathbf{w}^{*,\top} \phi(\mathbf{x}) + b^* \\ &= \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}) + b^* \\ &= \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b^* \end{aligned}$$




非线性支持向量机

□ 核技巧

想一想

核函数的作用是什么？

- 核函数替代了对任意两个向量“做映射—求内积”的繁琐运算



非线性支持向量机

□ 核技巧

● 核函数的定义

- 若存在一个从输入空间 $\mathcal{X}$ 到特征空间 $\mathcal{H}$ 的映射 $\phi: \mathcal{X} \rightarrow \mathcal{H}$, 对于任意 $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{X}$, 有函数 $\kappa: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 满足

$$\kappa(\mathbf{x}_1, \mathbf{x}_2) = \langle \phi(\mathbf{x}_1), \phi(\mathbf{x}_2) \rangle = \phi(\mathbf{x}_1)^\top \phi(\mathbf{x}_2)$$

- 则称该函数 κ 为一个核函数。

其中: $\langle \cdot, \cdot \rangle$ 为内积运算, $\mathbb{R}$ 为实数集



非线性支持向量机

□ 核技巧

● 核函数的性质

- 首先定义核函数 $\kappa(\cdot, \cdot)$ 关于样本 $(x_1, x_2, \dots, x_n)$ 的核矩阵:

$$\mathbf{K} = \begin{pmatrix} \kappa(x_1, x_1) & \kappa(x_1, x_2) & \dots & \kappa(x_1, x_n) \\ \kappa(x_2, x_1) & \kappa(x_2, x_2) & \dots & \kappa(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ \kappa(x_n, x_1) & \kappa(x_n, x_2) & \dots & \kappa(x_n, x_n) \end{pmatrix}$$



非线性支持向量机

□ 核技巧

● 正定核函数的充要条件：


- 给定对称函数 $\kappa: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ ，则该函数是正定核函数的充要条件是，对任意长度的一组数据 $(x_1, x_2, \dots) \in \mathcal{X}$ ，其核矩阵 K 半正定。

* 存在部分核函数不是正定核函数

* 对称函数：

$$\kappa(x_i, x_j) = \kappa(x_j, x_i)$$

* 延伸阅读：Mercer定理（关于正定核函数更严谨的定义）



非线性支持向量机

□ 常用核函数

- 如何设计**核函数**?
 - 直接设计新的核函数难度很大：帽子核
 - 常用的核函数包括：
 - 线性核、多项式核、**高斯核**、有理二次核、Matérn核、正弦平方核、神经网络核等。
 - 针对非结构化输入，如文本等数据，常用的核函数有：
 - 字符串核、Fisher核等。

Liu, Z., Lyu, C., Huo, J., Wang, S., and Chen, J.*, 2022. Gaussian Process Regression for Transportation System Estimation and Prediction Problems: the Deformation and a Hat Kernel, *IEEE Transactions on Intelligent Transportation Systems*, DOI:[10.1109/TITS.2022.3155527](https://doi.org/10.1109/TITS.2022.3155527).



非线性支持向量机

□ 常用核函数

● 线性核函数

- 不做任何映射，特征空间不做变换。

$$K_{\text{linear}}(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$$

● 多项式核函数

$$K_{\text{poly},d}(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$$

试一试

当多项式次数为2，特征维度也为2时，能否找到多项式核的映射 $\phi(\cdot)$ ？



非线性支持向量机

□ 常用核函数

● 多项式核函数

- 不妨记 $\mathbf{x}_i = (x_i^{(1)}, x_i^{(2)})^\top$

$$\begin{aligned} K_{\text{poly},2}(\mathbf{x}_i, \mathbf{x}_j) &= (\mathbf{x}_i^\top \mathbf{x}_j)^2 \\ &= (x_i^{(1)} x_j^{(1)} + x_i^{(2)} x_j^{(2)})^2 \\ &= (x_i^{(1)} x_j^{(1)})^2 + 2x_i^{(1)} x_j^{(1)} x_i^{(2)} x_j^{(2)} + (x_i^{(2)} x_j^{(2)})^2 \\ &= \left((x_i^{(1)})^2, \sqrt{2}x_i^{(1)} x_i^{(2)}, (x_i^{(2)})^2 \right)^\top \left((x_j^{(1)})^2, \sqrt{2}x_j^{(1)} x_j^{(2)}, (x_j^{(2)})^2 \right) \end{aligned}$$



$$\phi(\mathbf{x}_i) = \left((x_i^{(1)})^2, \sqrt{2}x_i^{(1)} x_i^{(2)}, (x_i^{(2)})^2 \right)$$

非线性支持向量机

□ 常用核函数

● 高斯核函数 / RBF(Radial Basis Function)核函数

$$\kappa_{\text{rbf}}(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

- σ 为带宽，是高斯核函数的一个超参数。
- 高斯核可改造为各向异性的核函数，以适应数据在不同特征维度上变化程度的差异。

$$\kappa_{\text{rbf}}(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{1}{2}(\mathbf{x}_i - \mathbf{x}_j)^\top \Sigma (\mathbf{x}_i - \mathbf{x}_j)\right)$$

$$\Sigma = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_k^2)$$

- Σ 为对角阵， k 为特征维度。



非线性支持向量机

□ 常用核函数

● 神经网络核函数 / Sigmoid核函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$$

- 超参数 β 和 θ 需要满足 $\beta > 0, \theta < 0$ 。
- 与线性核和多项式核一样，神经网络核可以写成关于 $x_i^\top x_j$ 的函数，此类核函数又称为点积核。
- **点积核正定性定理**：一个点积核 $\kappa(x_i, x_j)$ 是正定核，当且仅当它的泰勒级数 $\sum_{n=0}^{\infty} a_n (x_i^\top x_j)^n$ 中，有任意 $a_n > 0$ 。



非线性支持向量机

□ 常用核函数

● 神经网络核的正定性

- 令 $t = \mathbf{x}_i^\top \mathbf{x}_j$, 设 $\beta = 1$ 。
- 神经网络核的三阶麦克劳林级数:

$$\begin{aligned}
 f(\mathbf{x}_i^\top \mathbf{x}_j) &= f(t) \\
 &= \tanh(t + \theta) \\
 &= \tanh \theta + \frac{1}{\cosh^2 \theta} t - \frac{\tanh \theta}{\cosh^2 \theta} t^2 \\
 &\quad - \frac{1}{3} (1 - \tanh^2 \theta) (1 - 3 \tanh^2 \theta) t^3 + o(t^4)
 \end{aligned}$$

- 假设麦克劳林展开各项系数均非负
- θ 取值范围矛盾
- 该核函数**非正定核**



- $\theta \geq 0$
- $\theta \in \mathbb{R}$
- $\theta \leq 0$
- $\theta \in \left(-\infty, \ln \frac{2-\sqrt{3}}{2}\right] \cup \left[\ln \frac{2+\sqrt{3}}{2}, +\infty\right)$



非线性支持向量机

□ 常用核函数

● 核函数构造规则

- 除了基础的核函数，也可以通过一些规则来构造新的核函数
- 已知 $\kappa_1(\cdot, \cdot)$ 和 $\kappa_2(\cdot, \cdot)$ 均为核函数，则它们的**数乘、求和、乘积**仍为核函数。

$$\kappa(\mathbf{x}_1, \mathbf{x}_2) = \begin{cases} c\kappa_1(\mathbf{x}_1, \mathbf{x}_2) \\ \kappa_1(\mathbf{x}_1, \mathbf{x}_2) + \kappa_2(\mathbf{x}_1, \mathbf{x}_2) \\ \kappa_1(\mathbf{x}_1, \mathbf{x}_2) \cdot \kappa_2(\mathbf{x}_1, \mathbf{x}_2) \end{cases}$$



非线性支持向量机

□ 常用核函数

● 核函数选择

- 训练样本较少，特征维度较高时，较为**简单的**核函数通常足以拟合训练集数据，此时复杂的核函数极易产生过拟合现象；
- 训练样本较多，特征维度较低时，更适合使用**较为复杂的**非线性核函数，它们能够更充分地挖掘数据之间的非线性关系；
- 训练样本极多，特征维度不高时，适合使用**线性核函数**，甚至更简单的逻辑回归模型，否则运算效率难以接受；
- 结合数据特点选择，如对于时间序列预测问题，可使用具有周期性特点的正弦平方核



非线性支持向量机

□ 试一试


- 使用非线性支持向量机对案例数据进行分类。

1. 生成案例数据

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import make_circles

X, y = make_circles(
    n_samples=100,
    noise=0.2, factor=0.5,
    random_state=1
)

plt.figure(figsize=(5, 5))
sns.scatterplot(
    x=X[:,0], y=X[:,1], hue=y, legend='full')
plt.show()
```




非线性支持向量机

□ 试一试

- 使用非线性支持向量机对案例数据进行分类。

2. 线性SVM



**显然不能对数据
进行合理分类**

非线性支持向量机

□ 试一试

- 使用非线性支持向量机对案例数据进行分类。

3. 训练非线性SVM

```
from sklearn.preprocessing import StandardScaler  
from sklearn.svm import SVC
```

数据标准化

```
X_ = StandardScaler().fit_transform(X)  
data = X_, y
```

构建非线性支持向量机，训练模型

```
clf = SVC(C=1, kernel='rbf', random_state=3)  
clf.fit(X_, y)
```

设置了核函数!



非线性支持向量机

□ 试一试

- 使用非线性支持向量机对案例数据进行分类。

4. 查看分类结果

```
def plot_predicted_proba(data, clf, h=0.02):  
    X, y = data  
  
    x_min, x_max = X[:, 0].min() - .5, X[:, 0].max() + .5  
    y_min, y_max = X[:, 1].min() - .5, X[:, 1].max() + .5  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),  
                          np.arange(y_min, y_max, h))  
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)  
  
    plt.figure(figsize=(5, 5))  
    plt.contourf(xx, yy, Z, cmap=plt.cm.RdBu, alpha=.8)  
    sns.scatterplot(x=X[:, 0], y=X[:, 1], hue=y, legend='full')  
    plt.xlim(x_min, x_max)  
    plt.ylim(y_min, y_max)  
    plt.show()
```

```
plot_predicted_proba(data, clf)
```




非线性支持向量机

□ 试一试

- 使用非线性支持向量机对案例数据进行分类。

4. 查看分类结果



Bingo~

支持向量机

□ 学习目标

- 了解支持向量机的基本概念
- 掌握线性可分支持向量机模型
- 掌握软间隔支持向量机模型
- 理解非线性支持向量机中的核函数
- **介绍序列最小优化算法（阅读内容）**



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 非线性支持向量机的对偶问题

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m.$$

- 决策变量数 = 样本数
- 采用通用二次规划程序求解计算效率低



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 坐标上升 (下降) 法


- 每次只优化一个变量

- 记优化目标函数为 $\max_{\alpha} g(\alpha)$

- While 未收敛:


- For $i = 1, 2, \dots, m$:

- $\alpha_i \leftarrow \operatorname{argmax}_{\alpha} g(\alpha_1, \dots, \alpha_{i-1}, \alpha, \alpha_{i+1}, \dots, \alpha_m)$



支持向量机模型求解

- 序列最小优化 (SMO) 算法 (阅读内容)
- 坐标上升 (下降) 法是否适用于支持向量机求解?



$$\sum_{i=1}^m \alpha_i y_i = 0$$

例如, 我们希望更新变量 α_1 , 但受上面的约束影响, 有 $\alpha_1 = -y_1 \sum_{i=2}^m \alpha_i y_i$, 因此 α_1 被固定住, 无法更新。

如何解决?

支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

- **SMO**: 每次优化两个变量!
- 每次迭代时, 选择两个不同的待优化变量 α_i 和 α_j , 固定其他变量, 求解使目标函数最优的 α_i 和 α_j 。
- 选择另外两个不同的待优化变量, 重复以上步骤, 直至目标函数最优值收敛。

关键问题

- 如何同时优化两个变量?
- 每一轮迭代选择哪两个变量进行优化?



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 双变量二次规划

- 考虑选定的两个待优化变量为 α_i 和 α_j ，本轮迭代的优化问题为：

$$\begin{aligned} \max_{\alpha_i, \alpha_j} \quad & \alpha_i + \alpha_j - \frac{1}{2} \alpha_i^2 \kappa(\mathbf{x}_i, \mathbf{x}_i) - \frac{1}{2} \alpha_j^2 \kappa(\mathbf{x}_j, \mathbf{x}_j) - \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) \\ & - \sum_{k \neq i, j} \alpha_i \alpha_k y_i y_k \kappa(\mathbf{x}_i, \mathbf{x}_k) - \sum_{k \neq i, j} \alpha_j \alpha_k y_j y_k \kappa(\mathbf{x}_j, \mathbf{x}_k) \end{aligned}$$

$$\text{s.t.} \quad \alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k = \zeta,$$

$$0 \leq \alpha_i, \alpha_j \leq C.$$



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

- 双变量二次规划
- 仅考虑第一个约束条件:

$$\begin{aligned} \max_{\alpha_i, \alpha_j} \quad & \alpha_i + \alpha_j - \frac{1}{2} \alpha_i^2 \kappa(\mathbf{x}_i, \mathbf{x}_i) - \frac{1}{2} \alpha_j^2 \kappa(\mathbf{x}_j, \mathbf{x}_j) - \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) \\ & - \sum_{k \neq i, j} \alpha_i \alpha_k y_i y_k \kappa(\mathbf{x}_i, \mathbf{x}_k) - \sum_{k \neq i, j} \alpha_j \alpha_k y_j y_k \kappa(\mathbf{x}_j, \mathbf{x}_k) \end{aligned}$$

- 对于输入特征向量 $\mathbf{x}$,
模型预测值记为 $u(\mathbf{x})$

$$u(\mathbf{x}) = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 双变量二次规划

- 模型预测值 $u(\mathbf{x}_i)$ 与真实值 y_i 之差记为 E_i

$$E_i = u(\mathbf{x}_i) - y_i = \sum_{j=1}^m \alpha_j y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) + b - y_i$$

- 不考虑第二个约束时 α_j 的最优解为

$$\alpha_j^u = \alpha_j + \frac{y_j (E_i - E_j)}{\eta}$$

$$\eta = \kappa(\mathbf{x}_i, \mathbf{x}_i) + \kappa(\mathbf{x}_j, \mathbf{x}_j) - 2\kappa(\mathbf{x}_i, \mathbf{x}_j)$$




支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

- 双变量二次规划
- 对第二个约束可视化展示 $0 \leq \alpha_i, \alpha_j \leq C$

- 蓝色区域为可行域




支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)


● 双变量二次规划

● 考虑第一个约束 $\alpha_i y_i + \alpha_j y_j = \zeta$

● 可行域减小到一条线段



$$y_i = y_j$$



$$y_i \neq y_j$$



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 双变量二次规划

- 考虑第二个约束时
 α_j 的最优解为

$$\alpha_j^* = \begin{cases} L, & \alpha_j^u < L; \\ \alpha_j^u, & L \leq \alpha_j^u \leq H; \\ H, & \alpha_j^u > H. \end{cases}$$

- 根据第一个约束,
得到 α_i 的最优解为

$$\alpha_i^* = \frac{1}{y_i} \left(\alpha_i y_i + y_j (\alpha_j - \alpha_j^*) \right) = \alpha_i + y_i y_j (\alpha_j - \alpha_j^*)$$



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 双变量二次规划

- 模型预测还需要计算偏置项 b

$$u(\mathbf{x}) = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

- 考虑支持向量 $(\mathbf{x}_s, y_s)$, 满足

$$y_s \left(\sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}_s) + b \right) = 1$$

- 对所有支持向量计算偏置项后
取其平均值, 提高数值稳定性

$$S = \{i \mid 0 < \alpha_i < C, i = 1, 2, \dots, m\}$$

$$b = \frac{1}{|S|} \sum_{s \in S} \left(y_s - \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}_s) \right)$$



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 选择待优化变量的启发式思路

- 若所有变量满足KKT条件, 则也满足约束 $0 \leq \alpha_i, \alpha_j \leq C$

$$\begin{cases} \alpha_i = 0 \Leftrightarrow y_i u(\mathbf{x}_i) \geq 1 \\ 0 < \alpha_i < C \Leftrightarrow y_i u(\mathbf{x}_i) = 1 \\ \alpha_i = C \Leftrightarrow y_i u(\mathbf{x}_i) \leq 1 \end{cases}$$

- 有研究指出, $0 < \alpha_i < C$ 对应的样本更容易违反KKT条件
- 第一个待优化变量: 遍历整个训练集和满足 $0 < \alpha_i < C$ 的样本, 挑选其中不满足KKT条件的变量



支持向量机模型求解

□ 序列最小优化 (SMO) 算法 (阅读内容)

● 选择待优化变量的启发式思路

● 回顾变量更新的公式：

● 变量更新幅度与 $|E_i - E_j|$ 有关

$$\alpha_j^u = \alpha_j + \frac{y_j(E_i - E_j)}{\eta}$$

● 第二个待优化变量：选择 $|E_i - E_j|$ 最大的变量进行更新



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (1) 读取数据

● 导入基础模块

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (1) 读取数据

● 读取、查看数据

```
df = pd.read_csv("DATASET-B.csv")  
print(len(df))
```

```
print(df.sample(10, random_state=233))
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (2) 探索性数据分析

● 缺失值检查

```
print(sum(df.isnull().any()))
```

● 描述性统计

```
features = ['aveSpeed', 'gridAcc', 'volume', 'speed_std', 'stopNum']  
print(df[features].describe())
```



支持向量机

□ 实践环节

- 使用Scikit-learn中的SVM模型进行网格拥堵分类
- (2) 探索性数据分析
 - 查看数据相关性

```
plt.figure(dpi=200)
corr = df[features + ["labels"]].corr()
sns.heatmap(corr, square=True)
plt.show()
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (2) 探索性数据分析

● 查看数据分布

```
fig, ax = plt.subplots(3, 2, figsize=(10, 3.5), dpi=200)
for axi, feature in zip(ax.ravel(), features):
    sns.boxplot(x=feature, y='labels', orient='h', data=df, fliersize=1, ax=axi)
plt.tight_layout()
plt.show()
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (3) 模型训练

● 导入机器学习模块

```
from sklearn.svm import SVC
from sklearn.model_selection import GridSearchCV, train_test_split
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import StandardScaler
```



支持向量机

□ 实践环节

- 使用Scikit-learn中的SVM模型进行网格拥堵分类
- (3) 模型训练
 - 数据采样（减少运算量，可尝试选取不同数据或全样数据）
 - 划分训练集-测试集

```
df_sample = df.sample(20000, random_state=233)
X = df_sample[features]
y = df_sample["labels"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=233)
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (3) 模型训练

● 数据标准化

```
scaler = StandardScaler()  
X_train = scaler.fit_transform(X_train)  
X_test = scaler.transform(X_test)
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (3) 模型训练

● 网格搜索超参数

课后练习

□ 使用贝叶斯优化调参

```
params = {  
    "kernel": ["rbf"],  
    "gamma": [0.1, 0.2, 0.5, 1],  
    "C": [10, 100, 1e3]  
}  
  
clf = GridSearchCV(SVC(), params, cv=5)  
clf.fit(X_train, y_train)  
print(clf.best_params_)
```



支持向量机

□ 实践环节

● 使用Scikit-learn中的SVM模型进行网格拥堵分类

● (3) 模型训练

- 模型预测、输出预测精度

试一试

- 尝试其他核函数、超参数，对比预测精度

```
y_pred = clf.predict(X_test)
acc = accuracy_score(y_test, y_pred)
print(acc)
```



支持向量机

□ 学习总结

- 支持向量机的基本概念
 - **线性可分 | 间隔 | 支持向量 | 分隔超平面**
- 线性可分支持向量机模型
 - **支持向量机基本型 | 支持向量机基本型的对偶问题**
- 软间隔支持向量机模型
 - **软间隔 | hinge损失 | 软间隔支持向量机 | 软间隔支持向量机的对偶问题**
- 非线性支持向量机中的核函数
 - **核技巧 | 非线性支持向量机 | 常见核函数 | 核函数构造方法**
- 序列最小优化算法
 - **坐标上升法 | 双变量优化**



支持向量机

□ 课后思考

- 支持向量机如何用来解决回归问题？

□ 阅读材料

- Scholkopf, B., Smola, A.J., 2001. **Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond.** MIT Press, Cambridge. 【深入讨论SVM】
- Bishop, C.M., 2006. **Pattern Recognition and Machine Learning.** Springer, New York. 【第6、7章，核函数在机器学习的应用】

